

폐쇄망 방문설치 — 사전 준비 상태 점검 (2026-07-14)

목적: 방문설치 D-day 전에 "무엇이 준비됐고, 무엇이 남았는가"를 한 장으로 관리. **기준 런북:**

`docs/AIRGAP_VISIT_INSTALL_RUNBOOK.md` (2026-07-14 갱신본) 대상: Rocky Linux 10 · RTX 6000 Ada ×8 · USB 반입 · 1차 (인프라)/2차(GPU+T2C) 분리

1. 자산 감사 결과 (2026-07-14 실시)

✓ 검증 통과

항목	결과
<code>docker-compose.airgap.yml</code> 문법	<code>docker compose config -q</code> 통과 (경고 0)
<code>scripts/build_airgap_bundle.sh</code> 문법	<code>bash -n</code> 통과. 런북 §2 전 과정 자동화 확인 (슬림 Dockerfile 자동 선택, Ubuntu staging 대비 Rocky10 컨테이너 rpm 수집, pg_dump 컨테이너 풀백 포함)
slim 서비스 정합	<code>--chat-template</code> 명시 ✓ (운영 검증 레시피 항목) · <code>--tensor-parallel-size 1</code> ✓ (NVLink 부재 대응) · <code>profiles: [gpu]</code> ✓
<code>.env.airgap.phase1.template</code>	fail-closed 필수값(SECRET_KEY/ADMIN_PASSWORD/LLM_API_KEY) 전부 포함, 1차 LLM 미설정 원칙 반영
슬림 이미지 구성	<code>Dockerfile.airgap</code> + <code>requirements.airgap.txt</code> (pandas 포함 → numpy 확보) + <code>.dockerignore</code> (data/train/results/docs/age 제외)
인증서 정합	<code>gen_selfsigned_cert.sh</code> CN 기본값 = nginx <code>server_name</code> (ccop.cslee.internal) = 컴포즈 마운트 경로 일치
법률 RAG v2 폐쇄망 호환	신규 런타임 의존성 0 — 슬림 이미지 그대로 동작. 임베딩 백엔드 없이 BM25-only 자동 강등 설계. 적재: <code>ingest_legal_corpus.py --no-embed</code> (런북 1차 검증에 선택 항목으로 추가됨)

🔧 금일 수정 (드리프트 해소)

- `docker-compose.airgap.yml`: 죽은 `chroma_data` 마운트 제거(v1 RAG 잔재), obsolete `version:` 키 제거
- `deploy/.env.airgap.phase1.template`: `VLLM_TAG` 권장값 `v0.6.3.post1` 로 확정 (근거 아래)
- 런북: §0.2/§9.3 자산 표에 번들 자동화 스크립트·슬림 Dockerfile 반영, §2에 자동화 안내 추가, §5 vLLM 태그 확정, 1차 검증에 법률 RAG 선택 항목 추가

📌 vLLM 태그 결정 근거

`vllm/vllm-openai:v0.6.3.post1` — 운영에서 검증된 서빙 레시피(vllm 0.6.3.post1 + transformers 4.46.x + `--chat-template` 명시, `docs/CHECKPOINT_20260616.md`)와 동일 버전. cu121 빌드이므로 R530+ 드라이버(신규 Rocky 10 드라이버 포함)에서 동작. 다른 태그로 바꾸려면 staging GPU에서 모델 로드+추론 1회 검증 후 반입 (과거 transformers 5.x 토큰라이저 호환 사고의 재발 방지).

2. 남은 결정 사항 (사람이 정해야 함)

범위 확정: 이번 방문은 1차(인프라)만. 2차(GPU+T2C)는 인프라 안정화 후 별도 방문 — D3은 그때 다룬다.

#	결정	권고	상태
D1	번들에 담을 소스 기준	PR #5/#7/#6 dev 머지 완료(58bf8b1) → 이 커밋 기준 번들 생성 완료	✅
D2	staging 머신 — linux/amd64 + 인터넷 + docker	학습 GPU 머신(ai-kyw-dev@192.168.1.133, Ubuntu 24.04) — Rocky10 컨테이너로 el10 rpm 수집	✅
D3	2차 NVIDIA 드라이버 버전	(이번 범위 아님 — 2차 방문 시 결정)	⏸ 보류
D4	DB 덤프 범위 — 전체 vs 경량 그래프만	경량(tccop_graph_v6 등 데모 3~4개)만, <code>osint_ontology</code> (689만) 금지. 단 시나리오 A(네이티브 16.9)에서는 V3 덤프호환 결과에 따라 CSV 재적재로 대체 가능 — DB팀 협의	⌚

번들 생성 결과 (2026-07-14 완료)

ai-kyw-dev@192.168.1.133:~/ccop_bundle_p1 (972MB, dev 58bf8b1 기준) — sha256 145/145 OK - 이미지 3종:
ccop_app:1.0 (627M, 슬림) · agensgraph:v2.13.2 (110M, 시나리오 B 폴백) · nginx:alpine (61M) - Docker CE el10
rpm 141개 · DB덤프 없음(`--skip-db`) · 소스 tar 18M(신규 자산 전부 포함, 실 .env 미포함, 인증서 포함) - 구버전은
~/ccop_bundle_p1.old_0702 · ~/ccop_test.stale_0702 로 보관(가역)

3. 남은 작업 (1차 방문까지)

staging 번들 생성은 완료(\$2). 아래만 남음:

- [] **DB 반입물 결정** (D4) — DB팀 협의: ① 경량 덤프 `db/tccopdb.dump.gz` 를 번들 `db/` 에 추가, 또는 ② 시나리오 A 대비 원천 CSV 세트. 결정 후 staging에서 `~/ccop_bundle_p1/db/` 에 넣고 `sha256sum` 재생성: `bash cd ~/ccop_bundle_p1 && rm -f SHA256SUMS && find . -type f ! -name SHA256SUMS -exec sha256sum {} \; > SHA256SUMS`
- [] **exFAT USB 적재** (8GB 이상): `bash cp -rv ~/ccop_bundle_p1 /run/media/$USER/USB/`
- [] **매체 반입 신청/승인** + 백신 검사 + 반출입 대장 (\$4)
- [] **현장 질문지 회신** — 시나리오 A 관련: 앱 컨테이너→호스트 :5333 접근을 위해 DBA에게 `pg_hba/listen_addresses` 확인 요청 (V5), 앱 전용 DB/계정 신설 협의 (V4)
- [] **현장 오프라인 문서 지참** — `deploy/field_kit/` PDF 인쇄 또는 USB 동봉

(참고) 2차 방문 시 — 이번 범위 아님

2차 번들(vLLM 이미지 v0.6.3.post1 + 모델 15GB + NVIDIA 드라이버 rpm, ~30GB/64GB USB)은 1차 안정화 후 별도 생성. 런북 \$5 참조. rsync 으로 `qwen25-t2c-v42_merged(15GB)` 수집 → 4샤드+config+tokenizer+chat_template.jinja 확인 NVIDIA local-repo rpm(rhel10) + `nvidia-container-toolkit rpm` 수집 → SHA256SUMS

4. 물리·행정 준비 (기술 외)

- [] USB 2본: **exFAT** 포맷 — 1차 8GB+ / 2차 64GB+ (FAT32 금지)
- [] 기관 매체 반입 신청서 제출 → 사전 승인 확보
- [] 반입 게이트 백신 검사 대응, 매체 반출입 대장 양식 확인
- [] 현장 질문지 회신 확보: ① GPU 8장이 대상 VM에 passthrough 되는가(아니면 별도 GPU 노드 → `SLLM\_ENDPOINT` 를 노드 IP로) ②
- [] 런북 인쇄본 또는 오프라인 사본 (현장에서 인터넷 없음) — ``scripts/build_doc_pdf.py docs/AIRGAP_VISIT_INSTALL_RUNBOOK``

5. D-day 시퀀스 요약 (런북 매핑)

[방문 1] 1차 — 인프라 (런북 \$3~4) 반입·무결성 검증(\$4.1) → Docker 오프라인 설치(\$4.2) → 이미지 load(\$4.3) → 소스 복원 +.env(\$4.4) → DB 복원(\$4.5) → 기동(\$4.6) → 검증 체크리스트(\$4.7) 실패 시: sllm 없이 인프라만 유지 (자연어 질의만 유예)

[방문 2] 2차 — GPU+T2C (런북 \$6~7, 1차 안정화 후) 드라이버(+Secure Boot MOK) → container-toolkit → nvidia-smi 8장 확인 → vLLM 이미지·모델 적재 → .env 세 줄 + --profile gpu → e2e 검증(\$7.3) 롤백: .env 세 줄 주석 → app 재기동 = 1차 상태 복귀 ...

5. 📢 현장 DB 선설치 반영 (2026-07-14 작업일지 접수)

현장 폐쇄망 VM에 AgensGraph 16.9 네이티브 선설치 확인 (포트 5333, Rocky 10.1, shared_buffers 32GB 튜닝 완료) — 상세:

`AIRGAP_SITE_DB_LOG_20260714.md`

계획 변경: 1차 설치는 시나리오 A(네이티브 DB)가 기본 — `docker-compose.airgap.nativedb.yml` 사용, DB 컨테이너 미기동. agensgraph 이미지는 풀백(시나리오 B) 보험으로 번들에 유지(~수백MB). `.env` 템플릿은

`DB_HOST=host.docker.internal / DB_PORT=5333` 기본값으로 갱신됨.

신규 검증 항목 (V1~V5, 현장 전 staging 리허설 권장):

- [] V1 문법 호환: 앱 Cypher 계층(`SET graph_path` · `cypher()` 래핑) ↔ AgensGraph 16.9 — 1차 검증의 '직접 Cypher 입력'으로 최우선 확인
- [] V2 Extensions: 작업일지 Extensions 공란 — 그래프 카탈로그· `uuid-oss` 가용 여부 `\dx` 확인, 부족 시 DBA에 설치 요청
- [] V3 덤프 호환: 운영 덤프(2.13/PG13) → 16.9 복원 리허설. 실패 시 플랜 B: 원천 CSV 반입 → 앱 ETL 재적재 (번들 db/ 에 CSV 세트 동봉 권장)
- [] V4 DB-계정 정책: `tccopdb` 신설 + 앱 전용 `ccop` 계정 (슈퍼유저 `hlucyber` 앱 사용 금지) — DBA 협의
- [] V5 접근 경로: `listen_addresses` · `pg_hba.conf` 에 docker 브리지 대역 허용 — DBA 협의

보안 지적 (고객사 전달): 기본 비밀번호 사용 중(일반/슈퍼유저) → 즉시 변경 권고. Archive Mode=No → 백업 정책 별도 수립.

이 문서는 준비 진행에 따라 체크박스를 갱신한다. 기술 상세는 전부 런북을 따르고, 여기는 상태 추적만 담당.